Reporte Técnico - Proyecto Módulo 6: Predicción inteligente de gasto en clientes e-commerce.

Nombre: Luis León Barrera

Curso: Fundamentos de Ciencia de Datos

Fecha: 14/03/2026

1. Objetivo del Proyecto

El presente proyecto desarrolla un modelo de aprendizaje supervisado para predecir el monto total de compra (Total_Amount) de los clientes. El objetivo es proporcionar al Departamento de Analítica una herramienta capaz de estimar el valor de vida del cliente basándose en variables demográficas y de comportamiento, permitiendo optimizar campañas de marketing y gestión de inventarios.

2. Análisis y Preprocesamiento de Datos

Identificación de Fuga de Datos (Data Leakage): Durante la exploración inicial, se detectó que las variables Quantity y Unit_Price permitían un cálculo aritmético directo del gasto. Se procedió a eliminarlas para garantizar que el modelo aprenda patrones de comportamiento reales y no simples operaciones matemáticas. En un inicio se probó con estas variables y el modelo se sobreajustaba.

Justificación de Regresión: Mediante el análisis de la variable objetivo, se confirmó una distribución numérica continua. Por tanto, se desestimaron modelos de clasificación en favor de algoritmos de regresión.

Ingeniería de Características: Se implementó un ColumnTransformer para automatizar:

- **Escalamiento:** Uso de StandardScaler (o RobustScaler) para normalizar variables numéricas y mitigar el impacto de valores atípicos. Inicialmente se trabajó con StandardScaler pero al ver que habían outliers se optó por usar RobustScaler que es menos sensible a estos datos.

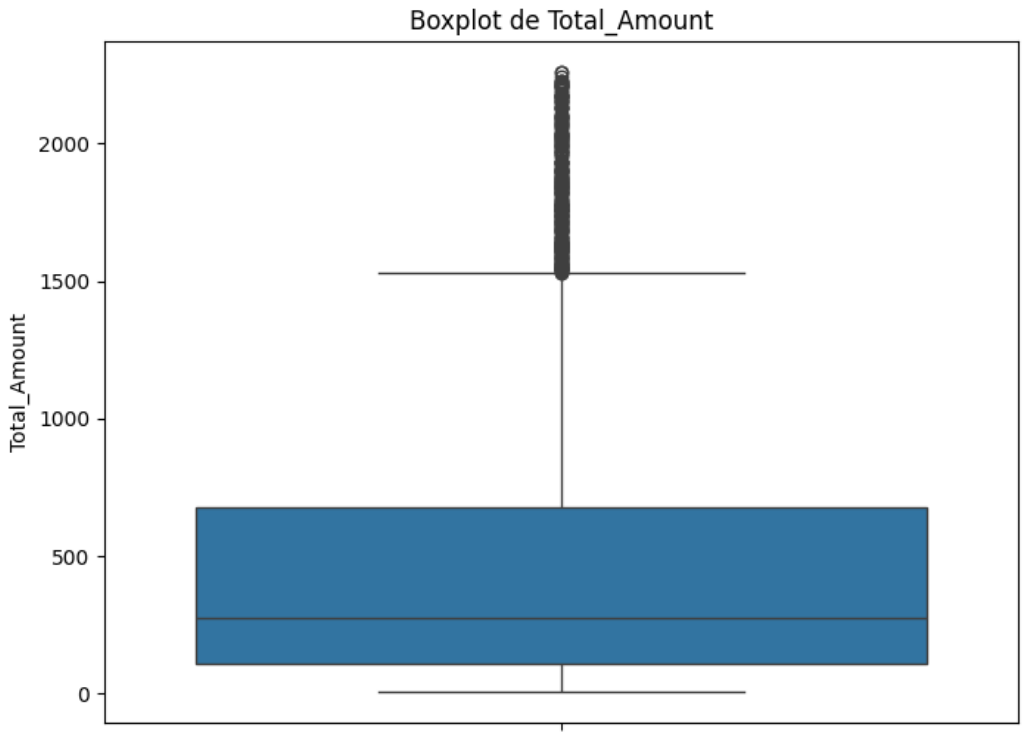

- **Codificación:** Uso de OneHotEncoder para transformar variables categóricas (City, Gender, Product_Category) en un formato procesable por los algoritmos.

3. Evaluación de Modelos y Optimización

Se compararon múltiples arquitecturas bajo una métrica de **Validación Cruzada (K-Fold, K=5)** para asegurar la estabilidad de los resultados:

Modelo	MAE (Error Medio)	R^2 (Varianza Explicada)
Regresión Lineal	225.59	0.603
Regresión Polinomial (Grado 2)	223.06	0.603
Lasso CV (Optimizado)	225.63	0.603
Gradient Boosting (Ganador)	**218.45**	**0.609**

Optimización en lección 7: Se utilizó GridSearchCV para sintonizar los parámetros de regularización en Lasso y Ridge. Lasso demostró ser ligeramente superior en el ámbito lineal al realizar una selección efectiva de variables, reduciendo el error cuadrático medio.

4. Diagnóstico del modelo final

El modelo seleccionado es **Gradient Boosting**, con un **R^2 de 0.609**.

Análisis de Residuos: El histograma de errores muestra una distribución normal centrada en cero, lo que valida al modelo como un estimador insesgado. La ligera cola derecha indica la dificultad natural de predecir compras "outliers" de muy alto valor.

Ausencia de Overfitting: La mínima brecha entre el error de entrenamiento MAE = 182.883 | R^2 = 0.739 y el de prueba MAE = 218.451 | R^2 = 0.609 confirma que el modelo generaliza correctamente hacia datos nuevos y no ha memorizado el ruido del set de entrenamiento.

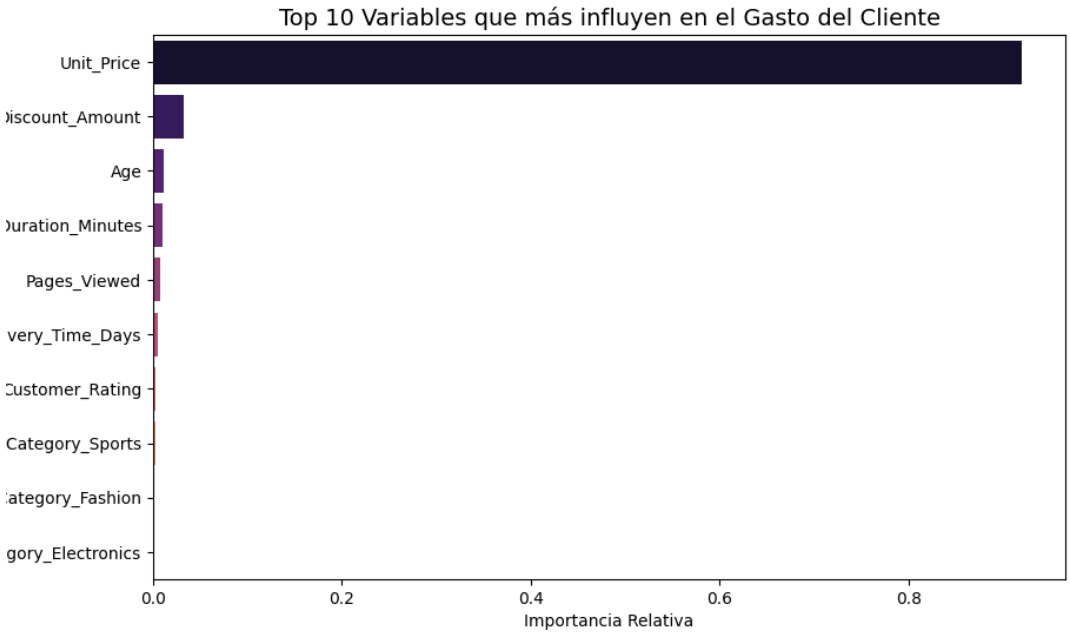

Como se observa en el histograma de distribución de errores, estos se centran alrededor del cero, agrupándose de forma normal, lo que es lo esperado.

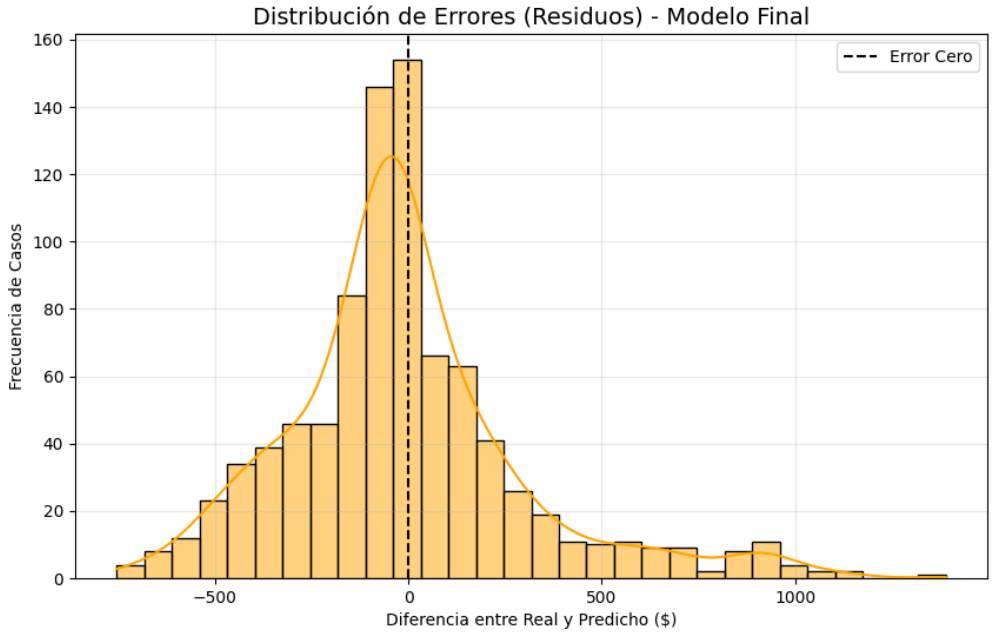

5. Conclusiones

Factores Predictivos: Las variables demográficas y el comportamiento en sesión explican el **60.9%** del comportamiento de gasto.

Precisión Comercial: Un **MAE de $218** permite una segmentación de clientes con un margen de error controlado para la planificación presupuestaria.

Simplicidad vs. Potencia: Aunque la regresión lineal es robusta, los métodos de ensamble (*Boosting*) son necesarios para capturar las interacciones no lineales entre las variables del e-commerce.